PONTIFICIA UNIVERSIDAD JAVERIANA · FACULTAD DE INGENIERÍA

Gestión de Datos
Clase 3

Integrar las fuentes y dejar los datos limpios: de nueve tablas sueltas a una vista única, sin huecos ni duplicados ni redundancia, con un agente de IA como copiloto.

👤 MSc. Edison Leonardo Neira Espitia

🧩 Limpieza de datos

🤖 Kiro + Olist



🗓️ AGENDA · 2 HORAS

La ruta de hoy: limpieza completa

Arranque	Integrar 9 tablas	No aportan	Faltantes	Atípicos y redundancia	Laboratorio Kiro	Kahoot y cierre
10 min	18 min	12 min	22 min	25 min	35 min	13 min

🧩 Integrar

Nueve tablas de Olist en una sola vista, y quitar lo que no aporta.

🕳️ Faltantes y atípicos

Por qué faltan los datos y cómo tratar valores imposibles y extremos.

🔗 Redundancia y fugas

Correlación, data leakage y causalidad. Todo en el proyecto Olist en Kiro.

Clase intensa: hoy cubrimos toda la limpieza. La siguiente clase es la vista minable.

☕ PARA ARRANCAR

¿Dónde se esconde la basura en tus datos?

En una frase, cuéntanos el **peor problema de calidad de datos** que has visto en tu trabajo o estudios.



Campos vacíos



Registros duplicados



Valores imposibles

Categorías inconsistentes

🤔 Guardemos tu ejemplo: hoy varios de esos problemas van a tener nombre y solución.

¿Por qué lo pregunto?

📱 REPASO DE LA CLASE 2

Saquen el celular: ¡Kahoot!

1. Entra a **kahoot.it** desde tu celular

2. Escribe el PIN del juego

000 000

3. Usa tu nombre real (suma a participación)

6 preguntas · 20 s cada una · repaso de la Clase 2

🎯 Qué repasamos

- Tipos de variable (nominal, ordinal, discreta, continua)
- Media vs. mediana con sesgo
- IQR y atípicos de Tukey
- Rol, Tarea y Formato en los prompts

¿Sin internet? Juguemos en pantalla y respondan a mano alzada.

▶ Modo juego en pantalla

🧭 EL HILO DEL CURSO

De explorar a limpiar

🎯 **Negocio**
Clase 1

→

🔍 **Explorar**
Clase 2

→

🧽 **Limpiar**
Clases 3 y 4

→

🧩 **Integrar**
Módulo 2

→

🏗️ **Escalar**
Módulo 3

📌 En la Clase 2 quedamos en...

Un diagnóstico: sabemos qué columnas tienen faltantes, cuáles están sesgadas y dónde hay atípicos. **Describimos** el dataset.

🧽 Hoy damos el salto a...

Transformar: unir las tablas en una sola y arreglar lo que el diagnóstico encontró. Empezamos por integrar y por los faltantes.

CONCEPTO

¿Qué es limpiar datos?

Corregir el mayor número de datos **erróneos, inconsistentes o irrelevantes**; remover o completar valores faltantes; e identificar o tratar los atípicos.

🧩 Completar y unir

- Integrar las nueve fuentes
- Atributos de valor único y constantes
- Alta unicidad (identificadores)
- Datos faltantes (MCAR, MAR, MNAR)

🎯 Corregir y depurar

- Duplicados
- Inconsistentes y atípicos
- Redundancia y correlación
- Data leakage y causalidad

🤖 Con agente

- El agente propone el código
- El código calcula
- **Tú** decides qué conservar

Hoy cubrimos **toda** la limpieza. En la Clase 4 transformamos esta vista limpia en la vista minable: normalizar y numerizar.

BLOQUE 1 · INTEGRAR

De muchas tablas a una vista única

Olist no es un archivo: son nueve tablas relacionadas. Para analizar y limpiar necesitamos una sola.



🧩 EL MODELO DE DATOS

Nueve tablas, una tabla de hechos



orders

tabla de hechos: un pedido por fila

customers · order_items · products · payments · reviews

+ geolocation, sellers, category_translation

🌟 Esquema estrella

orders es el centro. Las demás tablas se enganchan por su llave: `customer_id`, `order_id`, `product_id`.

Analizar sobre tablas separadas obliga a repetir *joins* en cada pregunta. Mejor construir una vez la vista única y limpiar sobre ella.

⚠️ Unir multiplica filas: como un pedido tiene varios ítems, al unir `order_items` una orden aparece en varias filas. Hay que tenerlo presente al contar.

🔗 PASO A PASO

Construyamos la vista única

Siguiente paso | Reiniciar

🤔 ¿Por qué `left` y no `inner` ?

Con **left join** conservamos todas las órdenes aunque les falte reseña o pago. Un **inner** borraría pedidos sin reseña y sesgaría el análisis.

💳 ¿Por qué agregar payments antes?

Un pedido puede tener varios pagos. Si uniéramos directo, cada pedido se multiplicaría otra vez. Primero sumamos el valor y concatenamos los tipos; así queda **un pago por pedido**.

PENSEMOS JUNTOS

El join que multiplica

Unes `orders` (99.441) con `payments` sin agregar primero, y el resultado tiene 103.886 filas. ¿Qué pasó?

A. Se perdieron pedidos: faltan filas

B. Algunos pedidos tienen varios pagos y se duplicaron en varias filas

C. El join estaba mal escrito y hay que usar inner

D. Es imposible: un join nunca cambia el número de filas

BLOQUE 2 · NO APORTAN

Atributos que no aportan

Antes de imputar nada, quitemos las columnas que no dicen nada: las constantes y las que son casi todas distintas.

🧹 ATRIBUTOS DE VALOR ÚNICO

¿Qué columnas sobran?

Toca cada fila para marcarla como **eliminar** o **conservar**; luego revela la recomendación.

COLUMNA	# DISTINTOS	EJEMPLO	DIAGNÓSTICO
money	1	"REAL"	Constante: el mismo valor en todas las filas
review_comment_title	— (88% nulos)	NaN	Casi todo vacío
order_id	99.441 (100%)	e481f...	Identificador único por fila
price	5.968	59.90	Variable analítica útil
payment_type	4	credit_card	Categórica con señal
review_score	5	4	Posible variable objetivo

eliminar conservar

🧱 Regla: elimina lo **constante** (un solo valor), lo **casi todo nulo** y los **identificadores** (100% distintos, sin poder predictivo).

Revelar recomendación

🔑 ALTA UNICIDAD

El umbral de unicidad

Mueve el umbral de % de valores distintos. Las columnas que lo superan son **candidatas a eliminar o jerarquizar**.

Umbral de unicidad: `80%`



🏗️ **Jerarquizar** en vez de borrar: una dirección exacta es única, pero `ciudad → barrio → dirección` agrupa. Súbela de nivel y gana poder analítico.

Columnas por unicidad

`order_id`	**100% · candidata**
`customer_unique_id`	**99% · candidata**
`product_id`	32%
`customer_city`	4.1%
`product_category_name`	0.07%
`payment_type`	0.004%
`review_score`	0.005%

BLOQUE 3 · FALTANTES

Datos faltantes

El problema más común y el que más decisiones exige. No todos los huecos se tapan igual.



DATOS PERDIDOS

Un hueco con muchas caras

Cómo se ve un faltante

No se almacenó ningún valor para una variable en una observación. Aparece como:

NaN | NA | ? | celda vacía | 0 | -1 | "N/D"

⚠️ Faltantes disfrazados

Lo más peligroso: un **0** en insulina o un **-1** en edad no son valores, son faltantes escondidos. Un conteo de nulos no los ve.

Lección de la Clase 2: 374 ceros de insulina eran, en realidad, datos ausentes.

🔎 Primer paso siempre: `df.isna().sum()` y su porcentaje. Pero revisa también los ceros y negativos imposibles del dominio.

🚀 MODERNIZACIÓN 2026

¿Por qué falta el dato? El mecanismo manda

Antes de imputar, pregúntate **por qué** falta. El mecanismo decide si imputar es seguro o si vas a inventar sesgo.

MCAR (Missing Completely At Random) · Faltante completamente al azar. El hueco no depende de nada (un sensor que falló aleatoriamente). Imputar por media o mediana es relativamente seguro.

MAR (Missing At Random) · Faltante al azar condicionado. Depende de *otra* variable observada (los jóvenes reportan menos su ingreso). Imputar **por grupo** o con un modelo que use esa otra variable.

MNAR (Missing Not At Random) · Faltante no al azar. Depende del *propio* valor ausente (los de ingreso muy alto no lo reportan). Imputar engaña: a veces el faltante es información y conviene marcarlo con una bandera.

🤖 Un agente puede sugerir el mecanismo probable, pero confirmarlo es criterio de negocio. Rellenar un MNAR con la media borra justo la señal que importaba.

🧰 ESTRATEGIAS

¿Qué hago con el hueco?

Eliminar fila | Eliminar columna | Media / mediana | Moda | Por clase | Deducir de otro atributo | Imputación avanzada (ML) | Dejar como faltante

1. Eliminar la fila
Borra el registro con el faltante. Úsalo solo si son muy pocos y están repartidos al azar (MCAR). Si borras muchas filas, pierdes datos y puedes sesgar.

2. Eliminar la columna
Si una variable es casi toda nula (por ejemplo 88%), aporta poco. Elimínala salvo que ese "faltante" sea en sí mismo información.

3. Media o mediana
Rellena con el centro de la columna. Media si es simétrica; mediana si está sesgada o tiene atípicos. Rápido, pero reduce la varianza.

4. Moda
Para variables categóricas o discretas: rellena con el valor más frecuente. Ojo si hay muchas categorías parejas.

5. Por clase
Imputa con la media o mediana del grupo al que pertenece el registro (por ejemplo, por categoría de producto). Útil cuando el faltante es MAR.

6. Deducir de otro atributo
Recupera el valor desde columnas relacionadas (por ejemplo, deducir la categoría a partir de las dimensiones del producto). Preciso cuando existe esa relación.

7. Imputación avanzada (ML)
Un modelo (KNN, MICE, regresión) predice el faltante usando las demás variables. Potente cuando hay estructura entre columnas; ajústalo solo con datos de entrenamiento.

8. Dejar como faltante
A veces el hueco es señal (MNAR). Márcalo con una bandera (una columna "era_nulo") y deja que el modelo lo aproveche en vez de inventar un valor.

🎛️ SIMULADOR · PREDICE ANTES DE REVELAR

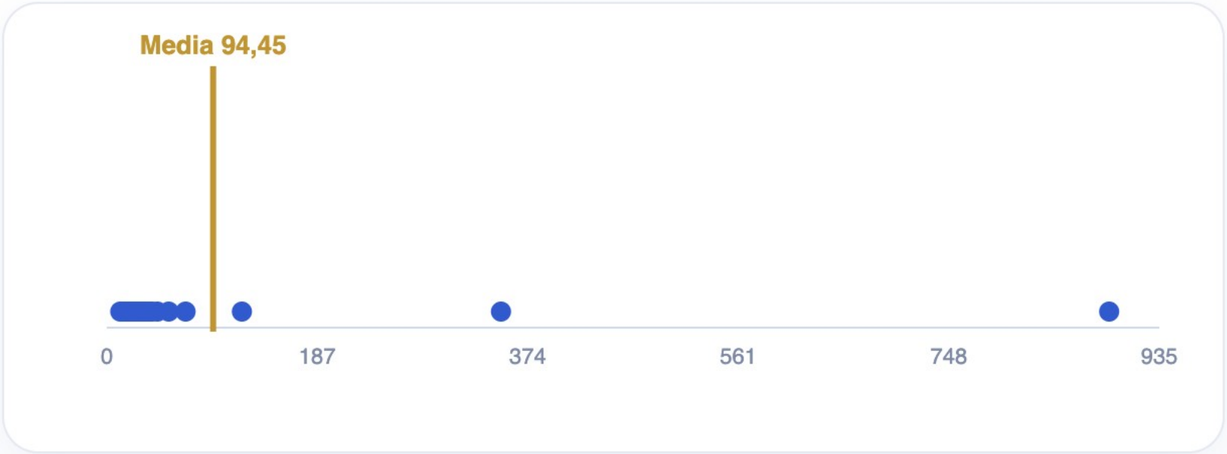
Imputar una columna sesgada

Columna `price` con cola larga (valores en miles). Tiene varios faltantes. ¿Con qué valor los rellenas?

Media | Mediana | Moda

MEDIA	MEDIANA	MODA
94,45	31,5	12

La media (94,45) se infla por los precios altos: rellenarías con un valor que casi nadie paga.



🚀 MODERNIZACIÓN 2026

Cuando la media no alcanza

El notebook base

Entrena un modelo (regresión / clasificación) para predecir el valor faltante a partir de las demás columnas. Correcto, pero artesanal.

Hoy

- **KNNImputer** (K-Nearest Neighbors, K vecinos más cercanos): usa los vecinos más parecidos.
- **IterativeImputer / MICE** (Multiple Imputation by Chained Equations): modela cada columna a partir de las otras, iterando.
- Siempre: ajustar el imputador **solo con train** y aplicarlo a test, nunca al revés.

⚖️ Más sofisticado no es siempre mejor: si el faltante es MCAR y son pocos, la mediana es suficiente y más explicable. Usa KNN/MICE cuando hay estructura entre variables que aprovechar.

PENSEMOS JUNTOS

Columna sesgada, 5% de faltantes

`freight_value` tiene cola larga a la derecha y un 5% de nulos aparentemente al azar. ¿Con qué la imputas?

A. Con la media, siempre es la mejor opción

B. Con la mediana: resiste la cola larga mejor que la media

C. Elimino la columna entera por tener nulos

D. Relleno con 0 para no complicarme

🤖 HUMANO + AGENTE

Quién hace qué en la limpieza

✅ El agente hace bien

- Escribir el código de perfilado de faltantes
- Proponer una estrategia por columna
- Implementar KNN/MICE sin que recuerdes la sintaxis
- Documentar el notebook

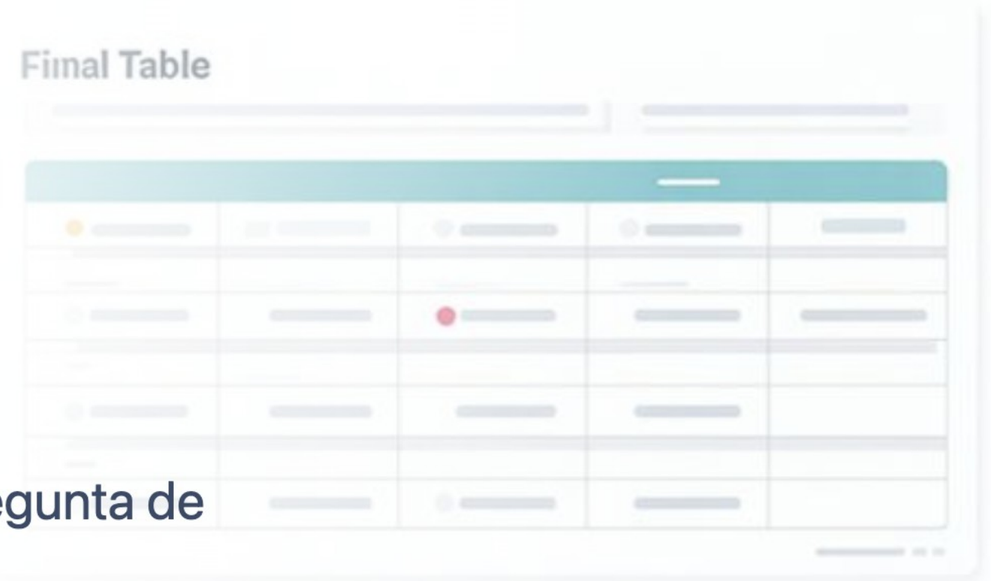
⚠️ Sigue siendo tuyo

- Decidir el mecanismo (MCAR/MAR/MNAR)
- Saber si un 0 es un valor o un faltante disfrazado
- Juzgar si imputar borra la señal
- Aprobar qué columnas se eliminan

🔁 **Regla de oro:** el agente propone, el código calcula, el analista valida. Ningún número del informe sale del chat.

BLOQUE 4

Duplicados, inconsistentes y atípicos



Valores fuera del dominio y valores extremos. La pregunta de fondo: ¿error o realidad?

REGISTROS DUPLICADOS

¿Cuáles filas sobran?

Toca el botón para resaltar las filas duplicadas que eliminaría `drop_duplicates()`.

ORDER	PRICE	PAYMENT	REVIEW
A	59.9	credit_card	5
B	120.0	boleto	4
C	35.5	credit_card	3
B	120.0	boleto	4
D	89.0	voucher	5

🧱 Un duplicado exacto repite todas las columnas. Pero cuidado: dos pedidos distintos con el mismo precio NO son duplicados.

Resaltar duplicados

🚫 FUERA DEL DOMINIO

Lo que no puede existir

Ejemplos imposibles

- Peso = `-1`
- N.º de hijos = `53`
- Ingreso = `-1000`
- Precio o flete `≤ 0` en Olist

¿Por qué aparecen?

- Error humano al digitar
- Fallas de medición o del instrumento
- Errores experimentales o de procesamiento
- A veces intencionales (para probar el sistema)

🔑 **Inconsistente ≠ atípico.** Un valor imposible por dominio (edad 156) es un error claro. Un atípico (precio muy alto) puede ser real. El tratamiento es distinto.

👁️ DETECCIÓN VISUAL

Ver para detectar

📊 Histograma y boxplot

Revelan colas y valores separados del grueso de los datos en **una variable**.

✴️ Scatter plot

Cruza dos variables (peso vs. consumo) y muestra puntos que se salen del patrón.

⚠️ Buena técnica con 1 o 2 variables. Con **muchas dimensiones** es difícil de visualizar y consume mucho tiempo: ahí necesitamos métodos estadísticos y multivariados (lo vemos en breve).

UMBRAL ESTADÍSTICO

El umbral de la normal: media ± 2σ

```
Edad =
{3,56,23,39,156,52,41,22,9,28,139,31,55,20,-67,37,11,55,45,37}
```

Media = 39,9 · Desviación = 45,65

Umbral = media ± 2·σ = **(−54,1 ; 131,2)**

Con dominio del atributo: (0 ; 131,2). Fuera de ahí → inconsistente.

⚠️ Límites del método

- Útil solo en distribuciones **simétricas**.
- La propia σ se infla por los atípicos.
- Detecta por atributo, **no** registros inconsistentes completos.

Por eso en la Clase 2 preferimos el IQR, que no depende de la media.

📦 REPASO APLICADO

IQR (rango intercuartílico): el método robusto

La regla

```
límite = Q1 − 1,5·IQR   a   Q3 + 1,5·IQR
```

No usa la media ni la σ, así que un atípico no mueve el umbral. Es el que usamos en Olist para `price`.

En el notebook

Para `price`: rango aceptado ≈ (–17 ; 350). Todo lo de arriba son candidatos a atípico, varios miles de filas.

Que sean candidatos no significa que se borren: hay que decidir el tratamiento.

SIMULADOR

Cinco formas de tratar un atípico

Columna con un extremo claro. Elige el tratamiento y mira qué pasa con la media y la forma.

Ignorar | Reemplazar por mediana | Winsorizar | Discretizar | Filtrar (eliminar)

Ignorar

No tocas nada. Válido solo si la técnica que usarás es robusta a atípicos.



MEDIA RESULTANTE	N.º DE FILAS
93,73	15

SIMULADOR

Cinco formas de tratar un atípico

Columna con un extremo claro. Elige el tratamiento y mira qué pasa con la media y la forma.

Ignorar | **Reemplazar por mediana** | Winsorizar | Discretizar | Filtrar (eliminar)



Reemplazar por mediana

Cambias el extremo por la mediana. Mantiene el tamaño pero altera el dato real.

MEDIA RESULTANTE	N.º DE FILAS
36,93	15

SIMULADOR

Cinco formas de tratar un atípico

Columna con un extremo claro. Elige el tratamiento y mira qué pasa con la media y la forma.

Ignorar | Reemplazar por mediana | **Winsorizar** | Discretizar | Filtrar (eliminar)

Winsorizar

Recortas el extremo al percentil superior (p90 aquí). Conservas la fila y baja la media.



MEDIA RESULTANTE	N.º DE FILAS
38,4	15

SIMULADOR

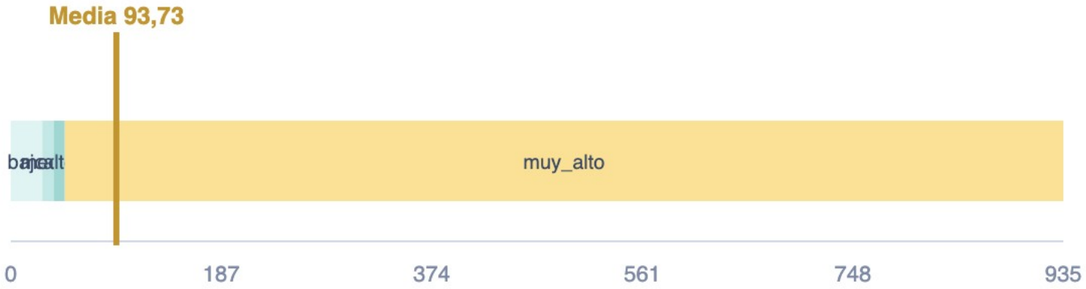
Cinco formas de tratar un atípico

Columna con un extremo claro. Elige el tratamiento y mira qué pasa con la media y la forma.

Ignorar | Reemplazar por mediana | Winsorizar | **Discretizar** | Filtrar (eliminar)

Discretizar

Agrupas en rangos (bajo/medio/alto/muy_alto). El extremo cae en "muy_alto".



MEDIA RESULTANTE	N.º DE FILAS
93,73	15

SIMULADOR

Cinco formas de tratar un atípico

Columna con un extremo claro. Elige el tratamiento y mira qué pasa con la media y la forma.

Ignorar | Reemplazar por mediana | Winsorizar | Discretizar | **Filtrar (eliminar)**

Filtrar (eliminar)

Borras la fila del extremo. Pierdes el registro: cuidado si es un dato real.



MEDIA RESULTANTE	N.º DE FILAS
36,86	14 (−1)

🚀 MODERNIZACIÓN 2026

Winsorizar: recortar sin borrar

La idea

En vez de eliminar el extremo, lo **recortas** al valor del percentil 5 o 95 más cercano. `df["price"].clip(p5, p95)`.

Conservas la fila (no pierdes el pedido) pero quitas el efecto del valor extremo.

Cuándo usarla

- El atípico es real pero distorsiona promedios.
- No quieres perder registros.
- Alternativa a eliminar o a transformar con logaritmo.

📉 En Olist, winsorizar `price` al p5-p95 baja la media de forma notable y suaviza la cola, sin tirar miles de pedidos reales.

🚀 MODERNIZACIÓN 2026

Cuando mirar no alcanza

El problema

Un registro puede ser normal en cada columna por separado, pero raro en combinación (un pedido barato con flete altísimo y entrega en 2 horas). El boxplot por columna no lo ve.

Métodos

- **Isolation Forest**: aísla los puntos raros con árboles aleatorios.
- **LOF** (Local Outlier Factor): compara la densidad de un punto con la de sus vecinos.
- Devuelven una puntuación de rareza por registro.

🤖 Un agente implementa Isolation Forest en segundos, pero **tú** revisas los registros que marca: algunos serán fraude o clientes VIP reales, no errores.

🪣 BUCKETIZACIÓN

Convertir el extremo en categoría

qcut en cuartiles

```
pd.qcut(price, 4, labels=["bajo","medio","alto","muy_alto"])
```

En vez de pelear con el valor exacto, lo agrupas en rangos. El atípico cae en "muy_alto" y deja de distorsionar.

bajo
Q1

medio
Q2

alto
Q3

muy_alto
Q4 · aquí caen los extremos

💡 Útil cuando el modelo o el negocio piensan en rangos ("gama alta") más que en el número exacto. Pierdes precisión, ganas robustez e interpretabilidad.

PENSEMOS JUNTOS

Precio con cola larga

`price` tiene miles de valores altos que son **productos caros reales**, no errores, pero distorsionan la media. ¿Qué haces?

A. Elimino todas las filas por encima de Q3 + 1,5·IQR

B. Winsorizo o discretizo: conservo los pedidos y controlo el efecto del extremo

C. Los dejo tal cual: los atípicos nunca se tocan

D. Los reemplazo todos por la media

Bloque 3 · 25 min

BLOQUE 5

Redundancia, fugas y causalidad

Columnas que se repiten, columnas que hacen trampa y correlaciones que engañan.

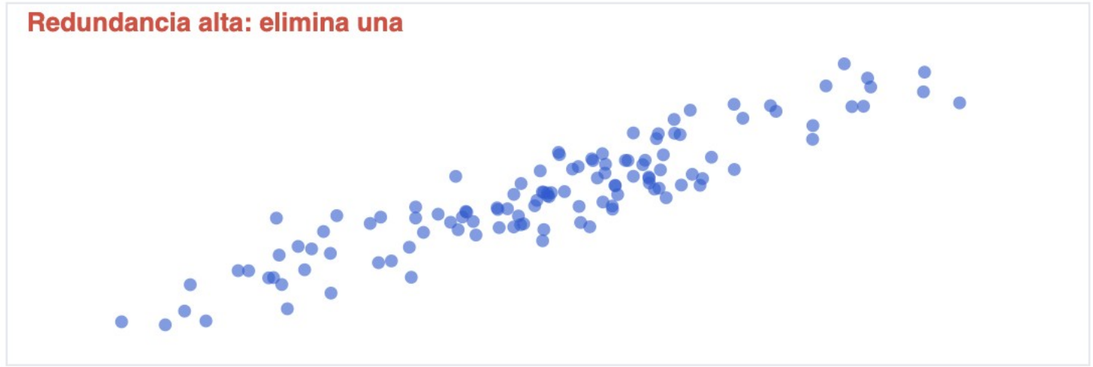
🔗 ATRIBUTOS REDUNDANTES

Correlación de Pearson

Mide la relación **lineal** entre dos variables, de –1 a 1. Mueve el valor y observa la nube de puntos.

Coeficiente r = `0.90`

🧹 Si dos *features* tienen |r| muy alto (por ejemplo peso y volumen del producto), aportan casi lo mismo: conserva una y elimina la otra para reducir redundancia.



MAPA DE CALOR

Ver toda la correlación de un vistazo



Cómo leerlo

- Azul fuerte = correlación positiva alta.
- Rojo fuerte = negativa alta.
- Casi blanco = sin relación lineal.

Busca pares muy azules o muy rojos entre *features*: son candidatos a redundancia. En Olist, las dimensiones del producto (largo, alto, ancho, peso) suelen correlacionar entre sí.

🚀 MODERNIZACIÓN 2026

Cuando Pearson se queda corto

Spearman. Pearson solo ve relaciones lineales. Si la relación es monótona pero curva (a más X, más Y, pero no en línea recta), Spearman la capta mejor porque trabaja con rangos.

Multicolinealidad (VIF). Dos columnas pueden tener correlación moderada entre pares y aun así una ser combinación de varias otras. El VIF (Variance Inflation Factor) detecta esa redundancia múltiple que una matriz de pares no muestra.

Relaciones no lineales. Información mutua y gráficos siguen siendo necesarios: dos variables con r = 0 pueden tener una relación fuerte en forma de U.

🤖 Pídele al agente la matriz de Pearson y la de Spearman, y que calcule el VIF. Tú decides qué eliminar según el negocio, no solo según el número.

SINÓNIMOS CON EL OBJETIVO

Columnas que hacen trampa (data leakage)

Atributos tan ligados a la variable objetivo que, en la práctica, **son** la respuesta o no existen al momento de predecir.

Fecha de reparación para predecir **si un equipo requiere reparación**: solo hay fecha si ya se reparó. El modelo "adivina" con trampa.

Número de asesinatos para predecir **si hubo fallecidos**: es prácticamente la misma variable.

En Olist: usar **review_score** para predecir si el cliente quedó satisfecho, cuando la reseña ocurre *después* de la entrega que quieres predecir.

⚠️ El leakage da modelos con precisión altísima en pruebas y que **fracasan en producción**. Un agente puede señalar columnas sospechosas; confirmar la línea de tiempo del negocio es tuyo.

🏴‍☠️ CORRELACIÓN ≠ CAUSALIDAD

Correlacionado no es causado

Correlaciones espurias

- Menos piratas y más calentamiento global (correlación casi perfecta, cero causa).
- Consumo de queso y muertes enredado en las sábanas (tylervigen.com).

Dos series que suben juntas no se causan: puede haber un tercer factor o pura casualidad.

🤖 En la era de los agentes

Un LLM, al ver una correlación alta, tiende a **redactar una explicación causal convincente** aunque no exista. Es su punto más débil.

Tu trabajo: exigir evidencia, diseño experimental o conocimiento del dominio antes de aceptar un "porque".

🧪 Para afirmar causa necesitas más que correlación: un experimento (A/B), control de variables o teoría del negocio. El agente propone hipótesis; la causalidad la defiendes tú.

PENSEMOS JUNTOS

Caza la fuga

Quieres predecir si un pedido se **entregará tarde**. ¿Cuál de estas columnas es data leakage?

A La ciudad del cliente

B El tipo de pago

C La fecha real de entrega al cliente

D El precio del producto

BLOQUE 6 · 35 MIN

Laboratorio agéntico

Seguimos el mismo proyecto Olist en Kiro. Nueva sección del notebook: integrar y tratar faltantes.

🏀 MISMO PROYECTO, NUEVA SECCIÓN

Retomamos donde quedó la Clase 2

Lo que ya tienes

- El contenedor (Docker o Podman) con Jupyter funcionando
- El archivo de steering en `.kiro/steering/`
- El notebook `eda_olist.ipynb` con el EDA

Lo que haremos hoy

Una nueva sección `## 7. Limpieza — integración y faltantes` en el mismo notebook, construida paso a paso con Kiro.

💰 Modelo y créditos

Seguimos con el presupuesto del plan Pro (1.000 créditos / mes, USD 20).

TAREA	MODELO
Análisis con pandas	**Qwen3 Coder Next** (0,05x)
Si falla dos veces	MiniMax M2.5 (0,25x)
Plan gratuito	Qwen3 Coder Next

Una tarea por prompt, con Rol, Tarea y Formato. No pegues datos: referencia el notebook con #.

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 8 · Integrar las tablas

```
ROL: Eres un ingeniero de datos experto en pandas.

TAREA: En el notebook eda_olist.ipynb agrega la sección "## 7.
Limpieza — integración". Construye una vista única partiendo de
orders:
1. orders + customers por customer_id (left).
2. + order_items por order_id (left).
3. + products por product_id (left).
4. payments: agrégalos antes por order_id (suma de payment_value como
total_payment_value, suma de payment_installments y concatenación
ordenada de payment_type), luego únelos (left).
5. + reviews (solo order_id, review_score, review_comment_title,
review_creation_date) por order_id (left).
Guarda el resultado en df y muestra su shape y el número de order_id
únicos.

FORMATO: Una celda por paso, cada una precedida de una celda markdown
corta en español que explique el join y por qué es left. No borres las
secciones anteriores.
```

🔲 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ La vista tiene más filas que orders (por order_items)
- ☐ order_id únicos sigue siendo 99.441
- ☐ payments quedó agregado: una fila por pedido

⏱ 8 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 9 · Unicidad y constantes

```
ROL: Eres un analista de calidad de datos.

TAREA: Agrega la subsección "## 7.1 Atributos que no aportan":
1. Calcula el número y el porcentaje de valores distintos por columna,
ordenado de mayor a menor.
2. Marca como candidatas a eliminar las columnas con unicidad mayor o
igual al 80% (identificadores) y elimínalas (order_id, customer_id,
customer_unique_id, product_id).
3. Detecta y elimina las columnas constantes (un solo valor distinto,
incluidos los nulos).
Muestra el shape antes y después de cada eliminación.

FORMATO: Código comentado en español y una tabla final con las
columnas eliminadas y el motivo. No inventes columnas: usa las que
existan en df.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ Se eliminaron los IDs de alta unicidad
- ☐ Se eliminó alguna columna constante si existe
- ☐ El shape disminuyó en columnas, no en filas

⏱️ 7 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | **Paso 10** | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 10 · Faltantes

```
ROL: Eres un analista experto en tratamiento de datos faltantes.

TAREA: Agrega la subsección "## 7.2 Datos faltantes":
1. Función faltantes(df) que devuelva, por columna, el conteo y el
porcentaje de nulos, ordenado de mayor a menor.
2. Elimina las columnas con más del 80% de nulos (como
review_comment_title) y justifícalo.
3. Para una columna numérica sesgada (por ejemplo product_length_cm o
price) imputa con la MEDIANA, no con la media, y explica por qué con
el sesgo calculado.
4. Para una categórica (product_category_name) primero intenta
deducirla desde las dimensiones del producto y, lo que quede, impútalo
con la moda.
Vuelve a mostrar la tabla de faltantes al final.

FORMATO: Una celda por estrategia, cada una con una celda markdown que
diga qué mecanismo de faltante asume (MCAR, MAR o MNAR).
```

🗒️ Copiar prompt

✅ Cómo saber que quedó bien

- ☐ La tabla final de faltantes queda en ceros o casi
- ☐ Usaste mediana en la columna sesgada, no media
- ☐ Cada imputación dice qué mecanismo asume

⏱️ 8 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 11 · Imputación avanzada

```
ROL: Eres un científico de datos que explica sus decisiones.

TAREA: Agrega la subsección "## 7.3 Imputación avanzada (opcional)".
Toma dos o tres columnas numéricas con faltantes y compáralas con tres
estrategias: mediana simple, KNNImputer y IterativeImputer (MICE) de
scikit-learn. Ajusta los imputadores solo con las columnas numéricas.
Muestra una tabla con la media y la desviación estándar de cada
columna según cada método y comenta en qué casos conviene cada uno.

FORMATO: Una celda de código y una tabla comparativa, más 3 viñetas de
conclusión. Si una conclusión no se sostiene con los números, dilo.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ Comparaste mediana vs KNN vs MICE con números reales
- ☐ Los imputadores se ajustaron solo con datos numéricos
- ☐ Concluiste cuándo vale la pena cada método

⏱️ 7 min · si falla, MiniMax M2.5

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | **Paso 12** | Paso 13 | Paso 14 | Paso 15

Paso 12 · Duplicados e inconsistentes

```
ROL: Eres un analista de calidad de datos riguroso.

TAREA: En eda_olist.ipynb agrega la sección "## 8. Limpieza – atípicos
y redundancia". Sobre el df limpio de la sección 7:
1. Detecta duplicados exactos (df.duplicated().sum()); muestra algunos
y elimínalos con drop_duplicates, reportando el shape antes y después.
2. Detecta valores inconsistentes por dominio en price, freight_value
y total_payment_value: filas con valor menor o igual a 0. Muéstralas y
decide (documentándolo) si se eliminan o se corrigen.

FORMATO: Una celda por punto, cada una con una celda markdown que
explique la decisión. No borres secciones anteriores.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ Reportaste duplicados antes y después
- ☐ Revisaste price/freight/payment menores o iguales a 0
- ☐ Cada decisión quedó justificada en markdown

⏱️ 8 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | **Paso 13** | Paso 14 | Paso 15

Paso 13 · Atípicos y winsorización

```
ROL: Eres un especialista en tratamiento de atípicos.

TAREA: Subsección "## 8.1 Atípicos":
1. Para price calcula los límites de Tukey (Q1 − 1,5·IQR, Q3 +
1,5·IQR) e informa cuántos atípicos hay y el porcentaje.
2. Crea price_wins winsorizando price al percentil 5 y 95 (clip).
Compara la media original vs la winsorizada y grafica ambas
distribuciones (KDE) en la misma figura.
3. Crea price_bucket con pd.qcut en 4 niveles (bajo, medio, alto,
muy_alto) y muestra su conteo.

FORMATO: Figuras con título y ejes en español, y una celda markdown
con 3 observaciones sobre el efecto de winsorizar. No inventes
resultados.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ Hay número y % de atípicos de price
- ☐ La media winsorizada es menor que la original
- ☐ Existen price_wins y price_bucket

⏱️ 8 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 14 · Correlación y leakage

```
ROL: Eres un científico de datos atento a la redundancia y a las fugas de información.

TAREA: Subsección "## 8.2 Redundancia y leakage":
1. Calcula la matriz de correlación de Pearson de las variables numéricas y dibújala como mapa de calor (annot=True).
2. Identifica los pares con |correlación| mayor o igual a 0,85 y propón conservar una sola variable de cada par, justificando cuál.
3. Revisa si alguna columna sería data leakage para predecir el review_score o el retraso de entrega (por ejemplo fechas posteriores a la entrega) y márcalas.

FORMATO: El mapa de calor, una tabla de pares redundantes con la columna a conservar, y una lista de columnas con riesgo de leakage y por qué.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ El mapa de calor se ve con valores
- ☐ Identificaste al menos un par redundante
- ☐ Señalaste al menos una columna con riesgo de leakage

⏱️ 8 min · Qwen3 Coder Next

🛠️ LABORATORIO · COPIA, PEGA EN KIRO Y VALIDA

Cada paso agrega una subsección al notebook. No borres lo anterior.

Paso 8 | Paso 9 | Paso 10 | Paso 11 | Paso 12 | Paso 13 | Paso 14 | Paso 15

Paso 15 · Exportar la vista minable

```
ROL: Eres un ingeniero de datos que entrega resultados reproducibles.

TAREA: Subsección "## 8.3 Vista minable":
1. Construye df_final conservando solo las columnas limpias y sin
leakage que acordamos.
2. Verifica: sin duplicados, sin nulos injustificados, tipos
correctos; imprime shape y dtypes.
3. Exporta a work/olist_vista_minable.csv con index=False.
4. Escribe una celda markdown "## 9. Conclusiones del Módulo 1" con 5
viñetas, cada una respaldada por una celda del notebook.

FORMATO: Código comentado en español y la celda de conclusiones.
Recuerda la bitácora: anota modelo y créditos de cada paso.
```

📋 Copiar prompt

✅ Cómo saber que quedó bien

- ☐ Existe el archivo olist_vista_minable.csv
- ☐ df_final no tiene nulos ni duplicados
- ☐ Las conclusiones citan celdas del notebook

⏱️ 6 min · Qwen3 Coder Next

PENSEMOS JUNTOS

El agente imputó con la media

Le pediste tratar los faltantes de `price` (cola larga) y rellenó con la **media**. ¿Qué haces?

A. Lo acepto: el agente sabe más que yo

B. Reinicio el notebook y pruebo suerte otra vez

C. Le indico que use la mediana por el sesgo y lo registro en la bitácora

D. Cambio a un modelo más caro para que no se equivoque

💬 PARA CERRAR

Una decisión, una duda, un dato

01

Una **columna de tu trabajo** que imputarías, y con qué estrategia.

02

Un **atípico** que tratarías (winsorizar o filtrar) y por qué.

03

Una **columna redundante** o una posible **fuga** que ahora reconocerías.

➡ SOON En la Clase 4: la vista minable (normalizar, numerizar, discretizar y balancear).

Mi síntesis

🏆 KAHOOT FINAL

¿Quién domina la integración y los faltantes?

Entra a **kahoot.it** e ingresa el PIN

000 000

8 preguntas · joins, unicidad, mecanismos de faltante e imputación

El podio gana puntos de participación 🥇🥈🥉

🎮 Respaldo sin internet

Mismas preguntas en pantalla, a mano alzada.

▶ Modo juego en pantalla

🧭 QUÉ SIGUE

Rumbo a la Clase 4: la vista minable

⚖️

Normalizar
poner todo en la misma escala

🔢

Numerizar
convertir categorías en números

📋

Vista minable
lista para el algoritmo

📌 Trae tu notebook con la limpieza de hoy terminada: en la Clase 4 transformamos esa vista limpia en la vista minable final del Módulo 1.

REFERENCIAS

Para profundizar

- Pyle, D. (1999). *Data Preparation for Data Mining*. Morgan Kaufmann.
- Kantardzic, M. (2011). *Data Mining: Concepts, Models, Methods and Algorithms*. 2.ª ed. Wiley.
- Han, J. (2012). *Data Mining: Concepts and Techniques*. 3.ª ed. Morgan Kaufmann.
- McKinney, W. *Python for Data Analysis*, 3.ª ed., capítulo de limpieza de datos.
- scikit-learn: *Imputation of missing values* (SimpleImputer, KNNImputer, IterativeImputer).
- Olist: Brazilian E-Commerce Public Dataset.