DEPARTAMENTO DE INGENIERÍA DE SISTEMAS
Gestión de Datos · Módulo 1 · 2026
MSc. Edison Leonardo Neira Espitia

Taller 2: Limpieza de Datos

Diagnóstico y limpieza de un dataset: faltantes, atípicos, duplicados y redundancia con apoyo de un agente de IA

Modalidad	Peso	Puntaje	Entrega
Grupal (3 personas)	20% (talleres del Módulo 1)	50 puntos	Fecha: _____

1. Objetivos de aprendizaje

- Diagnosticar la calidad de un dataset: valores faltantes (incluidos los disfrazados), atípicos, duplicados, inconsistentes y redundantes.
- Distinguir los mecanismos de faltante (MCAR, MAR y MNAR) y elegir una estrategia de imputación justificada.
- Aplicar las funciones de pandas para limpiar: dropna, fillna, drop, drop_duplicates y Boolean Indexing (indexación booleana).
- Tratar atípicos con criterio (límites de Tukey y winsorización) y detectar redundancia con correlación, evitando el data leakage (fuga de información).
- Usar un agente de IA de forma responsable: documentar cada prompt y validar cada número con código ejecutado.

2. Entorno de trabajo

Trabaja en el **mismo entorno de contenedores de la Clase 3** (Docker o Podman con Jupyter Lab). Si no puedes ejecutarlo, usa un entorno virtual de Python o Google Colab e indícalo en tu entrega.

Notebook	Uno solo: work/taller2_<apellidos>_<nombres>.ipynb, con una sección por ejercicio.
Librerías	pandas, numpy, scipy, matplotlib, seaborn y ydata-profiling.
Dataset	Titanic: https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv
Agente	Kiro u otro IDE agéntico. Recomendado: Qwen3 Coder Next para análisis; Claude Haiku 4.5 si algo falla dos veces.
Diccionario	Significado de las columnas: https://www.kaggle.com/c/titanic/data

3. Reglas para trabajar con el agente

1. **El agente propone, el código calcula, tú validas.** Ningún número del informe puede venir del chat: debe salir de una celda ejecutada en tu notebook.
2. Usa prompts con la estructura **Rol, Tarea y Formato**. Una tarea por prompt.
3. Registra cada prompt en la **bitácora agéntica** (sección 6).
4. Las interpretaciones y conclusiones las escribes **tú**. Puedes pedirle al agente que las revise, no que las redacte.
5. Si el agente instala librerías, cambia rutas o inventa columnas, corrígelo y anótalo en la bitácora: eso también suma.

4. Ejercicio 1: Diagnóstico de calidad de los datos (20 puntos)

Carga el dataset de Titanic y, pensando que esos datos van a entrar luego a un **modelo predictivo**, diagnostica su calidad. Para cada columna reporta los hallazgos y propón una acción de mitigación.

4.1 Carga y vistazo inicial

6. Carga titanic.csv con pd.read_csv y muestra las 10 primeras filas, el shape y los tipos de dato (dtypes).
7. Genera el reporte exploratorio con ydata-profiling y guárdalo en HTML. Úsalo como apoyo, pero toda conclusión debe verificarse con una celda propia.

4.2 Tabla de diagnóstico por columna

Construye una tabla (una fila por columna, las 12 columnas) con estas verificaciones y, en la última columna, la acción de mitigación propuesta:

Valores únicos o constantes	Columnas con un solo valor (no aportan) o con un valor por fila (identificadores como PassengerId, Name, Ticket).
Valores faltantes	Número y % de nulos. Indica el mecanismo probable: MCAR (falta completamente al azar), MAR (al azar condicionado a otra variable) o MNAR (depende del propio valor).
Faltantes disfrazados	Ceros o marcadores imposibles que en realidad son nulos (por ejemplo Fare = 0, o categorías como "?" o "Unknown").
Valores atípicos (por atributo)	Para las numéricas (Age, Fare, SibSp, Parch): límites de Tukey (Q1 - 1,5·IQR, Q3 + 1,5·IQR), número y % de atípicos.
Registros atípicos	Filas completas que combinan valores extremos (por ejemplo tarifa altísima con clase baja). Explóralas.
Redundancia o nulo valor	Columnas muy correlacionadas o que miden lo mismo (SibSp y Parch frente a tamaño de familia), y columnas sin valor predictivo.

Entregable del ejercicio: la tabla de diagnóstico con la acción de mitigación por columna, el HTML de ydata-profiling y una celda markdown que señale cuál es la columna más problemática y por qué.

5. Ejercicio 2: Limpieza del dataset (20 puntos)

Aplica las correcciones que planeaste. Debes usar **al menos una vez cada una** de estas funciones, y justificar en markdown cada decisión:

df.dropna	Remover filas o columnas con demasiados nulos
df.fillna	Imputar nulos con un valor por defecto justificado
df.drop	Eliminar columnas que no aportan o que son identificadores.
Boolean Indexing	Filtrar subconjuntos y corregir inconsistencias
df.drop_duplicates	Detectar y eliminar filas duplicadas, reportando el shape antes y después.

Además de usar esas funciones, realiza:

8. **Faltantes:** decide por columna entre eliminar o imputar y justifícalo con el mecanismo (MCAR, MAR o MNAR). Compara la media y la mediana de Age antes y después de imputar.
9. **Atípicos:** trata Fare con winsorización (clip a los percentiles 5 y 95) o con los límites de Tukey. Compara la media original con la tratada y grafica la distribución antes y después.
10. **Redundancia:** calcula la correlación entre las numéricas, crea la variable derivada tamano_familia = SibSp + Parch + 1 y decide qué columnas conservar. Señala cualquier columna con riesgo de data leakage.
11. Exporta el dataset limpio a titanic_limpio.csv con index=False e imprime el shape final y los dtypes.

Entregable del ejercicio: titanic_limpio.csv, las figuras de antes y después, y una celda markdown que resuma qué se eliminó, qué se imputó y cuántas filas y columnas quedaron.

6. Bitácora agéntica (5 puntos)

Al final del notebook, una tabla con todos los prompts que usaste. Formato mínimo:

#	Prompt (Rol, Tarea, Formato)	Modelo	Créditos	Qué corregí o validé yo
1	ROL: analista de calidad de datos. TAREA: imputar Age y Embarked en titanic.csv justificando el mecanismo de faltante... FORMATO: una celda comentada y una tabla antes/después	Qwen3 Coder Next	0,06	Imputó Age con la media; lo cambié a la mediana por el sesgo y lo verifiqué

Se evalúa la calidad de los prompts, la honestidad del registro y el criterio para corregir al agente, no la cantidad de prompts.

7. Conclusiones del analista (5 puntos)

Escribe con tus palabras, **sin el agente**, entre 5 y 8 conclusiones sobre el proceso de limpieza. Cada una debe citar la celda que la respalda (por ejemplo: "la columna Cabin se eliminó por 77% de nulos, ver celda 12"). Después puedes pedirle al agente que las revise y anotar qué cambiaste.

8. Entregables

Un archivo Taller2_Apellidos_Nombres.zip con:

- El notebook .ipynb **ejecutado de principio a fin** (Kernel, reiniciar y ejecutar todo), sin errores.
- titanic_limpio.csv y el reporte HTML de ydata-profiling.
- Los archivos del entorno (Dockerfile, docker-compose.yml, requirements.txt) o la indicación del entorno alternativo usado.

Integridad académica. Usar un agente de IA está permitido y es parte del taller. Presentar como propio un número que no salió de tu código, o conclusiones redactadas por el agente sin declararlo en la bitácora, se considera una falta.

9. Rúbrica de evaluación

Criterio	Excelente (100%)	Aceptable (60%)	Insuficiente (20%)
Diagnóstico (20)	Tabla completa por columna con mecanismo de faltante y acción de mitigación justificada	Diagnóstico parcial o sin acciones de mitigación	Solo el reporte automático, sin análisis propio
Limpieza (20)	Usa las 5 funciones con criterio, trata faltantes, atípicos y redundancia, y exporta el dataset	Limpia pero sin justificar o sin tratar atípicos/redundancia	Aplica funciones sin criterio ni justificación
Bitácora (5)	Prompts con RTF, modelo, créditos y correcciones del humano	Prompts listados sin correcciones	Sin bitácora
Conclusiones (5)	Conclusiones propias, cada una respaldada por una celda	Conclusiones generales sin evidencia	Sin conclusiones o redactadas por el agente

Reproducibilidad	El notebook corre de principio a fin sin errores	Corre con advertencias menores	No se ejecuta completo

Total: 50 puntos. Un notebook que no se ejecuta de principio a fin tiene una penalización del 20%.